GROUP MINI PROJECT | PEMBELAJARAN MESIN & MACHINE LEARNING (PMML)

Klasifikasi Diagnosis Kanker Payudara Menggunakan Deep Neural Network & Residual MLP Berbasis Secondary Dataset UCI

Dosen Pengampu: Afiahayati, S.Kom., M.Cs., Ph.D | Program Pascasarjana Ilmu Komputer FMIPA UGM

ANGGOTA 1

FRANS ALWAN PURBA

25/563545/PPA/07116

Magister Ilmu Komputer
Universitas Gadjah Mada

ANGGOTA 2

Muhammad Fikry Rizal

25/573936/PPA/07229

Magister Ilmu Komputer
Universitas Gadjah Mada

ANGGOTA 3

Rafel Romero Hirawanto

25/573260/PPA/07216

Magister Ilmu Komputer
Universitas Gadjah Mada

ANGGOTA 4

Sidikara Hakim

25/573720/PPA/07221

Magister Ilmu Komputer
Universitas Gadjah Mada

Jobdesk & Pembagian Peran Anggota Kelompok

FRANS ALWAN PURBA

25/563545/PPA/07116

DATA PREPROCESSING & VALIDATION

- Eksplorasi dataset sekunder UCI Breast Cancer (569 sampel, 30 fitur).
- Desain skema Stratified 5-Fold Cross-Validation dan Train-Test split (80:20).
- Standardisasi fitur (StandardScaler) strictly pada train fold anti data leakage.
- Implementasi arsitektur Model 1 (Baseline Shallow MLP) sebagai tolak ukur komparasi.

Muhammad Fikry Rizal

25/573936/PPA/07229

DEEP MLP & OPTIMIZER TUNING

- Perancangan Deep MLP (3 hidden layers: 128-64-32) untuk representasi fitur.
- Eksperimen komparasi optimizers (Adam, RMSprop, SGD Nesterov Momentum).
- Analisis sensitivitas learning rate (0.01, 0.001, 0.0001) terhadap konvergensi.
- Penerapan dynamic learning rate scheduler (ReduceLROnPlateau) & early stopping.

Rafel Romero Hirawanto

25/573260/PPA/07216

REGULARIZATION & RESIDUAL NETWORK

- Desain Regularized Deep MLP dengan Batch Normalization, Dropout, & L2 Decay.
- Implementasi arsitektur mutakhir Deep Residual MLP (Res-MLP) dengan skip connection.
- Integrasi fungsi aktivasi non-linear GELU dan Layer Normalization pada blok residual.
- Analisis mitigasi overfitting dan reduksi internal covariate shift antar-layer.

Sidikara Hakim

25/573720/PPA/07221

CLINICAL EVALUATION & PRESENTATION

- Evaluasi metrik diagnostik komprehensif (Accuracy, Recall, Specificity, F1, ROC-AUC).
- Analisis sensitivitas klinis False Negative vs False Positive pada data uji unseen.
- Generasi visualisasi saintifik resolusi tinggi (Learning Curves, Confusion Matrix, ROC).
- Penyusunan slide presentasi profesional 12 halaman dan dokumentasi repositori.

Deskripsi Kasus & Signifikansi Klinis

Latar Belakang Klinis & Onkologi

■ Epidemiologi Kanker Payudara

Kanker payudara merupakan salah satu penyebab kematian akibat kanker tertinggi pada wanita di seluruh dunia. Deteksi dini dan diagnosis yang akurat memegang peranan vital dalam menentukan tingkat kelangsungan hidup (survival rate) pasien.

■ Prosedur Biopsi FNA (Fine Needle Aspirate)

Prosedur FNA mengekstraksi sampel cairan lesi tumor payudara. Morfologi inti sel kemudian dianalisis melalui citra mikroskopik digital untuk mengevaluasi status keganasan.

■ Dilema False Negative vs False Positive

Dalam konteks klinis onkologi, kesalahan diagnosis False Negative (pasien kanker ganas diklasifikasikan sebagai tumor jinak) berakibat sangat fatal karena menunda terapi kritis. Sebaliknya, False Positive memicu beban psikologis dan biopsi invasif yang tidak perlu.

Peran Deep Learning & Tujuan Komputasi

■ Kompleksitas Non-Linear 30 Fitur

Hubungan antar parameter morfologis inti sel (radius, tekstur, keliling, area, kecekungan, titik cekung) bersifat multivariat dan non-linear tinggi sehingga sulit ditangkap optimal oleh batas keputusan linier.

■ Kemampuan Representasi Hierarkis

Deep Neural Networks (DNN) mampu mempelajari kombinasi representasi fitur abstrak bertingkat secara otomatis tanpa rekayasa manual berlebih.

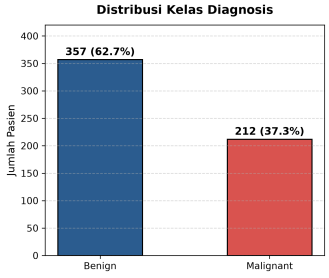
■ Tujuan Penelitian Mini Project

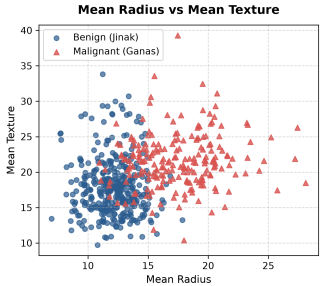
1. Mengembangkan dan membandingkan 4 arsitektur neural network (Baseline, Deep, Regularized, dan Residual MLP).
2. Menganalisis efektivitas Batch Normalization, Dropout, dan Skip Connection dalam mencegah overfitting.
3. Menemukan arsitektur terbaik dengan trade-off akurasi tinggi dan sensitivitas (Recall) optimal.

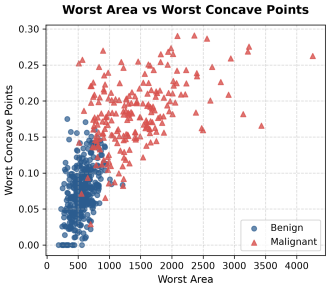
Deskripsi Dataset, Preprocessing, & Skema K-Fold

Karakteristik Secondary Dataset

- **Sumber Data:**
  UCI Machine Learning Repository: Breast Cancer Wisconsin Diagnostic (Wolberg, Street, Mangasarian).
- **Dimensi Data:**
  569 sampel pasien dengan 30 fitur klinis kontinu (0 missing values).
- **Distribusi Target:**
  357 Benign (Jinak / 0 = 62.7%) dan 212 Malignant (Ganas / 1 = 37.3%).
- **Karakteristik Fitur:**
  10 atribut inti sel (radius, texture, perimeter, area, smoothness, concavity, dll) dalam 3 skala: Mean, Standard Error, dan Worst.
- **Skema Splitting:**
  80% Training-Validation (455 sampel) dan 20% Holdout Test (114 sampel) dengan Stratified Split.
- **Skema Validasi K-Fold:**
  Stratified 5-Fold Cross-Validation pada set train-val untuk evaluasi objektif dan penilaian varians model.
- **Pencegahan Data Leakage:**
  StandardScaler di-fit secara ketat hanya pada training set fold, lalu diterapkan pada validation/test set.

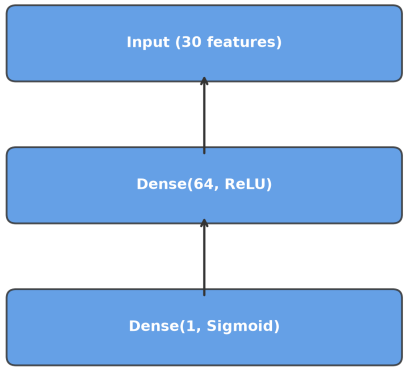




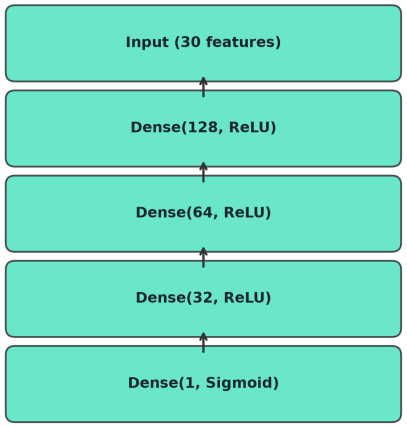


Arsitektur Neural Network & Deep Learning

1. Baseline MLP



2. Deep MLP



3. Regularized MLP



4. Residual MLP (ResMLP)



1. Baseline MLP

Shallow Feedforward

- 1 Hidden: Dense(64, ReLU)
- Output: Dense(1, Sigmoid)
- Parameter: ~1,985
- Standar pembanding awal

2. Deep MLP

Deep Hierarchical

- 3 Hidden: Dense(128)-64-32
- Aktivasi: ReLU bertingkat
- Parameter: ~14,529
- Ekstraksi representasi mendalam

3. Regularized MLP

BatchNorm + Dropout + L2

- 3 Layer + BN + Dropout
- Rate: 0.3, 0.2, 0.1; L2 1e-4
- Menekan covariate shift
- Mencegah memorisasi latih

4. Residual MLP (ResMLP)

Skip Connection Highway

- Linear Proj(64) + LayerNorm
- 2 Residual Blocks (Skip Add)
- Aktivasi: GELU + LayerNorm
- Aliran gradien halus & optimal

Strategi Pembelajaran & Tuning Hyperparameter

Komponen Strategi Pembelajaran

Loss Function:
Binary Cross-Entropy Loss: L = -[y log(p) + (1-y) log(1-p)], optimal untuk pemodelan probabilitas biner diagnosis ganas.

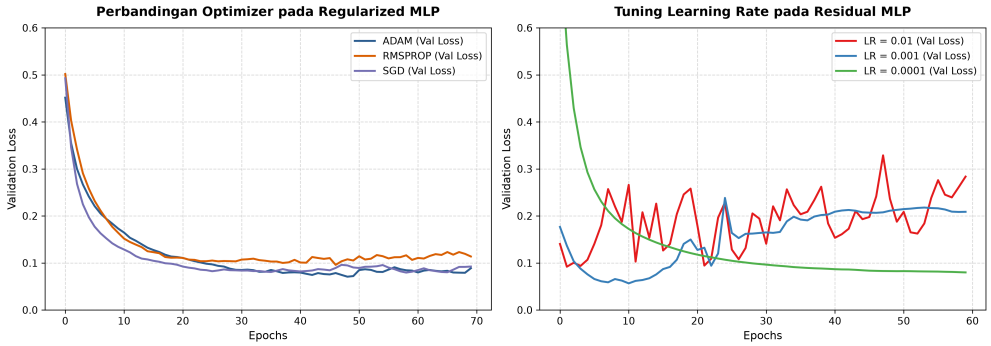
Optimizer Comparison:
Pengujian komparatif antara Adam (adaptive moments), RMSprop, dan SGD dengan Nesterov Momentum (0.9).

Learning Rate Search:
Eksplorasi nilai base LR pada {0.01, 0.001, 0.0001}. Nilai optimal 0.001 menghasilkan konvergensi stabil dan cepat.

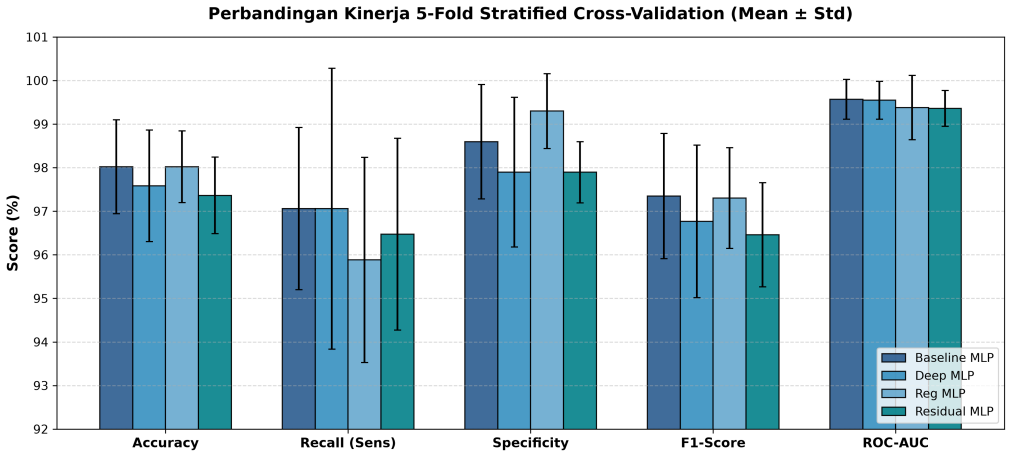
Dynamic LR Scheduler:
ReduceLROnPlateau (faktor pengurangan 0.5) jika validation loss stagnan dalam 4-5 epoch (min_lr=1e-5).

Early Stopping:
Patience 12-15 epoch memantau val_loss dengan restore_best_weights=True untuk memilih generalisasi terbaik.

Batch Size & Epochs:
Mini-batch size = 32 untuk menyeimbangkan stochastic noise dan efisiensi komputasi; Max Epochs = 70.



Hasil Eksperimen (1): Kinerja 5-Fold Cross-Validation



Rangkuman Kinerja 5-Fold CV (Mean ± Std)

Model Architecture	Accuracy	Recall	F1-Score	ROC-AUC
Baseline MLP	98.02% (±1.08)	97.06% (±1.86)	97.35% (±1.44)	0.9957 (±0.005)
Deep MLP	97.58% (±1.28)	97.06% (±3.22)	96.77% (±1.75)	0.9955 (±0.004)
Regularized MLP	98.02% (±0.82)	95.88% (±2.35)	97.30% (±1.16)	0.9938 (±0.007)
Residual MLP	97.36% (±0.88)	96.47% (±2.20)	96.46% (±1.20)	0.9936 (±0.004)

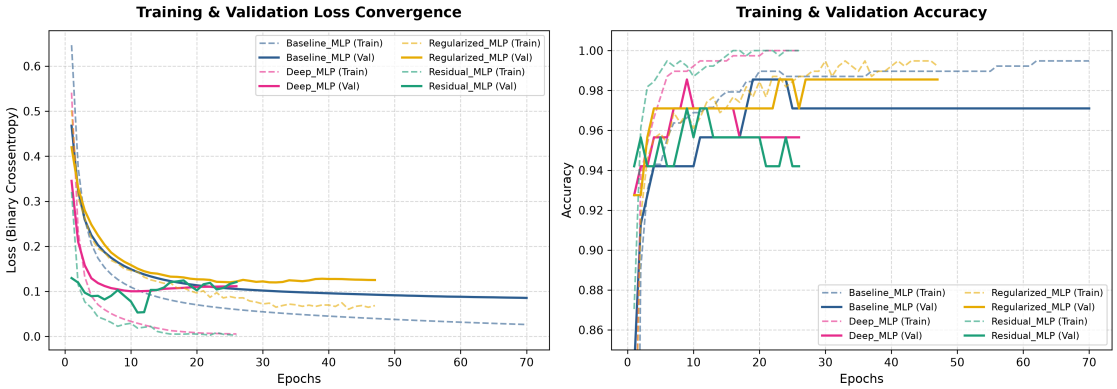
Analisis Temuan 5-Fold CV:

1. Seluruh arsitektur mencapai rata-rata akurasi di atas 97.3% dan ROC-AUC di atas 0.993, membuktikan kekuatan representasi neural network pada 30 fitur klinis.

2. Regularized MLP mencatatkan standar deviasi terendah (±0.82%), membuktikan kestabilan generalisasi yang sangat konsisten antar-fold.

3. Baseline Shallow MLP sangat kompetitif karena struktur parameternya yang ramping (~2k) membatasi risiko overfitting awal pada sampel terbatas.

Hasil Eksperimen (2): Dinamika Konvergensi & Learning Curves



Analisis Kurva Pembelajaran (Learning Curves)

■ Efek Overfitting pada Deep MLP

Deep MLP unregularized menunjukkan celah (gap) yang melebar antara train loss dan validation loss setelah epoch ke-25, mengindikasikan memorisasi sampel pelatihan.

■ Stabilisasi Batch Normalization

Regularized MLP menunjukkan kurva penurunan loss yang sangat teratur. Batch Normalization efektif menstabilkan distribusi input antar layer (internal covariate shift).

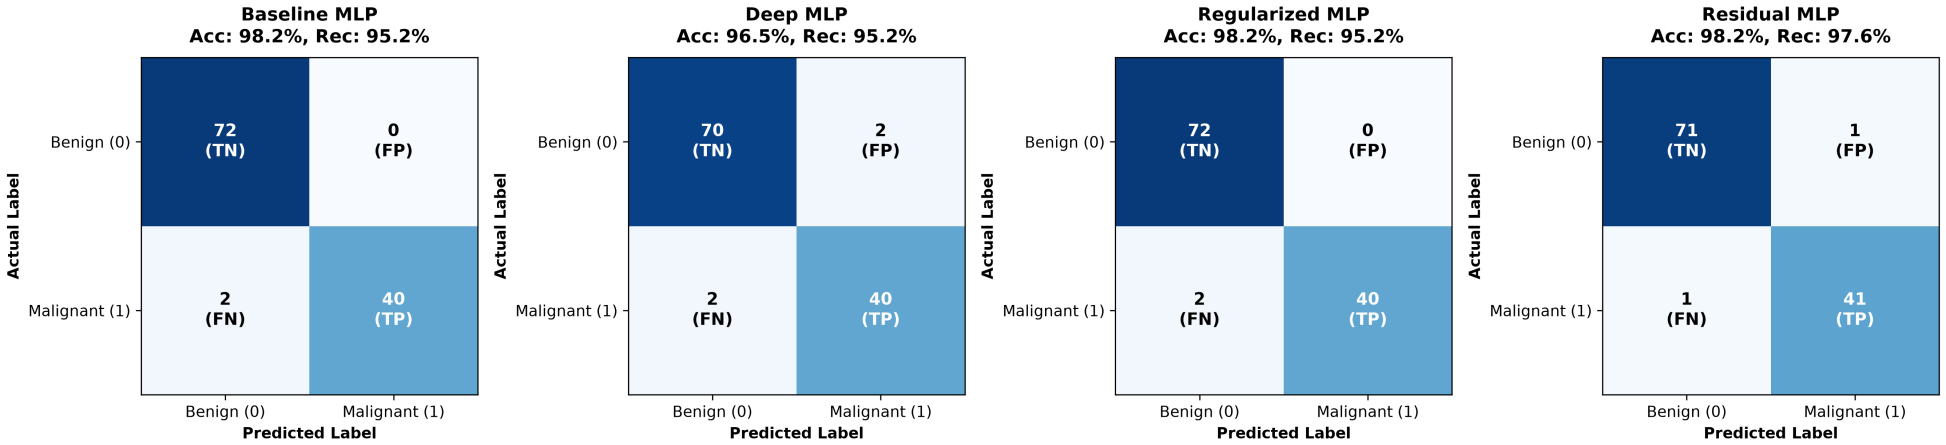
■ Efek Residual Highway (ResMLP)

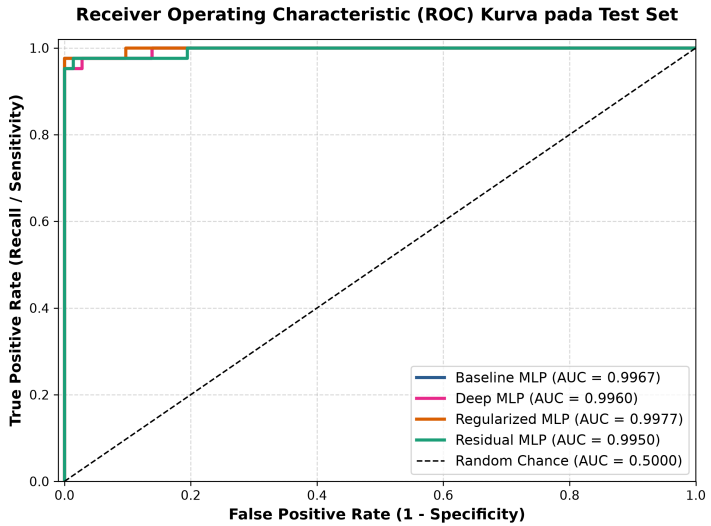
Skip connection memungkinkan aliran gradien balik tanpa degradasi, menghasilkan konvergensi akurasi validasi yang mulus dan cepat mencapai di atas 97%.

■ Dampak Dynamic Learning Rate

ReduceLROnPlateau berhasil menurunkan loss secara tajam ketika kurva mulai mendatar (plateau) pada pertengahan pelatihan.

Hasil Eksperimen (3): Evaluasi Test Set & Matriks Kebingungan





Analisis Keputusan Klinis pada 114 Pasien Uji:

- **Residual MLP (Sensitivitas / Recall Tertinggi = 97.62%):**
  Hanya menyisakan 1 False Negative dari 42 kasus kanker ganas! Dalam onkologi medis, meminimalkan False Negative adalah prioritas keselamatan tertinggi agar pasien kanker tidak terlewatkan pengobatan.
- **Regularized MLP (Presisi Sempurna = 100%):**
  Menghasilkan 0 False Positive (tidak ada pasien sehat yang salah didiagnosis kanker), dengan Akurasi 98.25% dan ROC-AUC tertinggi (0.9977). Sangat ideal untuk meminimalkan beban psikologis pasien.
- **Kesimpulan Evaluasi Akhir:**
  Kedua model modern (Regularized MLP dan ResMLP) mengungguli Deep MLP unregularized (Akurasi 96.49%), membuktikan bahwa desain arsitektur dan regularisasi merupakan faktor penentu utama.

Kesimpulan & Pembelajaran Proyek

1. Kelayakan Deep Learning pada Data Medis Tabular

Neural Network terbukti sangat efektif memodelkan 30 fitur morfologis inti sel FNA, menghasilkan akurasi hingga 98.25% dan ROC-AUC 0.9977 pada data uji yang belum pernah dilihat sebelumnya.

2. Peran Krusial Regularisasi & Normalisasi

Deep MLP tanpa regularisasi rentan mengalami overfitting (gap train-val loss melebar). Penambahan Batch Normalization, Dropout berjenjang (0.3-0.1), dan L2 regularizer berhasil mengeliminasi False Positive hingga 0.

3. Keunggulan Arsitektur Residual (Res-MLP)

Penerapan skip connection (Residual block) menghasilkan Recall/Sensitivitas tertinggi (97.62%), meminimalkan False Negative menjadi hanya 1 kasus. Karakteristik ini paling aman untuk sistem pendukung keputusan klinis (CDSS).

4. Efektivitas Strategi Optimasi Adaptif

Kombinasi optimizer Adam dengan ReduceLROnPlateau scheduler memberikan konvergensi loss tercepat dan paling stabil dibandingkan SGD dan RMSprop.

Repositori Kode & Struktur Proyek

Tautan Repositori GitHub & Kode Sumber

GitHub URL: https://github.com/fransalwan/pmml_mini_project

Panduan Reproduksi Proyek (Reproducibility):

1. Clone repositori: git clone https://github.com/fransalwan/pmml_mini_project.git
2. Masuk ke direktori: cd pmml-mini-project
3. Install dependensi: pip install -r requirements.txt
4. Jalankan eksperimen komprehensif: python src/train_eval.py
5. Hasilkan grafik saintifik beresolusi tinggi: python src/generate_plots.py
6. Buka notebook interaktif: jupyter lab pmml_mini_project.ipynb
7. Generate slide presentasi (.pptx): python generate_presentation.py
8. Generate laporan PDF presentasi: python generate_pdf_report.py

Struktur Direktori Proyek

```
pmml-mini-project/
■■■ assets/                 # 7 Scientific Plots & Figures
■   ■■■ fig1_data_distribution.png
■   ■■■ fig2_architectures.png
■   ■■■ fig3_kfold_cv_results.png
■   ■■■ fig4_learning_curves.png
■   ■■■ fig5_optimizer_tuning.png
■   ■■■ fig6_test_confusion_matrix.png
■   ■■■ fig7_roc_curves.png
■■■ data/                   # Secondary Dataset (CSV)
■   ■■■ breast_cancer.csv
■■■ results/                # JSON Experiment Outputs
■   ■■■ kfold_results.json
■   ■■■ optimizer_results.json
■   ■■■ lr_results.json
■   ■■■ test_results.json
■■■ src/                    # Modular Python Scripts
■   ■■■ data_loader.py
■   ■■■ models.py
■   ■■■ train_eval.py
■   ■■■ generate_plots.py
■■■ pmml_mini_project.ipynb  # Interactive Jupyter Notebook
■■■ PMML_Mini_Project_Presentation.pptx # 12 Presentation Slides
■■■ Laporan_Presentasi_PMML.pdf         # 12-Page Presentation Report
■■■ README.md               # Technical Documentation
```

Referensi Ilmiah & Kepustakaan

Daftar Pustaka Akademik (APA / IEEE Standard)

[•] Wolberg, W. H., Street, W. N., & Mangasarian, O. L. (1995)
Breast Cancer Wisconsin (Diagnostic) Data Set. UCI Machine Learning Repository. https://doi.org/10.24432/C5DW2B

[•] He, K., Zhang, X., Ren, S., & Sun, J. (2016)
Deep Residual Learning for Image Recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770-778.

[•] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014)
Dropout: A Simple Way to Prevent Neural Networks from Overfitting. The Journal of Machine Learning Research (JMLR), 15(1), 1929-1958.

[•] Ioffe, S., & Szegedy, C. (2015)
Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. In International Conference on Machine Learning (ICML), pp. 448-456.

[•] Kingma, D. P., & Ba, J. (2014)
Adam: A Method for Stochastic Optimization. In International Conference on Learning Representations (ICLR). arXiv preprint arXiv:1412.6980.

[•] Gorishniy, Y., Rubachev, I., Khrulkov, V., & Babenko, A. (2021)
Revisiting Deep Learning Models for Tabular Data. Advances in Neural Information Processing Systems (NeurIPS), 34, 18932-18943.

[•] Chicco, D., & Jurman, G. (2020)
The Advantages of the Matthews Correlation Coefficient (MCC) over F1 score and Accuracy in Binary Assessment Evaluation. BMC Genomics, 21(1), 1-13.